viewstamp replication

1. 前言

Viewstamps算法是Oki和Liskov于1988年发表的论文，Liskov是一位计算机世界中杰出的女性，08年图灵奖得主、著名面向 对象五原则中“Liskov可替换原则”的提出者。我们已无精力考证Viewstamps是否是第一个多数派表决的算法，但知道其比 Paxos（1998）整整早了10年，杯具的是，随着06年googlechubby论文发表，Paxos迅速闻名于世，而Viewstamps依旧寂寂无闻。

2. 问题的由来

在分布式系统中一般通过复制来提高系统的可用性，而复制又引入了一致性的问题，比如我们把数据复制到A、B、C三个节点，如何保证A、B、C看到的复制数据的顺序是一致的？从深层次上来讲，复制节点就是一个状态机，我们有必要时刻保证各状态机状态的一致。

为了保证复制数据的一致性，**Viewstamps采用了Primary-backup模式（类Master-slave），规定所有数据操作，无论是查询还是更新都必须通过primary进行，然后传递到各backup**（显然primay-backup与数据库的master-slave还是不同 的，数据库的master-slave强调的是“单写多读”），这样，数据的一致性就得到了保证，但primary会成为单点，如果primary crash那进行一半的事务该如何处理？这正是viewstamps算法要解决的问题，所以viewstamps也经常被描述为master的选举算法。

3. 概念

- Primary Service被复制（部署）多份，每份复制称为backup，primary与众多的backup组成一个group，提供与一个primary相同的逻辑功能。
- group里的每个成员又被称为cohort，cohort可以是primary也可以是backup。
- group里的全部cohor又称为configuration，group更多是描述性的称呼，而configuration是指要在配置文件中把这个关系固定下来，是配置性的称呼。
- configuration中超过1/2的成员又称为多数派(majority)，viewstamps允许2N+1个节点中的N个节点同时失败。
- 在某一时刻，系统的状态是有一个primary与几个backup提供服务（未必是所有的backup），这种状态称为view。
- 在某个primary或backup crash后，这个view就会被打破，从而形成新的view，这个过程叫view change，而viewstamps又自称为view change算法。

另外补充几个次重要概念：

- 每个group都有一个groupid，是配置好的，不能更改
- 每个view都有一个viewid，动态生成
- 每个cohort都有一个唯一的id
- 每个primary都有一个queue用来保证数据一致性，queue中的数据按照timestamp的顺序（先后顺序）保持数据
- primary每次与backup通信称为event
- 每个event必定发生在某个view中，event又是根据timestamps的顺序传递数据，因此算法叫viewstamps。
- 事务：viewstamps 中的事务实现方式都是二段提交，即prepare和commit两个阶段。

存在众多繁杂且表述不一的概念，也是viewstamps算法的一大特色，翻来覆去就那么几样东西，大家习惯即可。

4. 调用过程

客户端C发送数据到primary，primary传播到backups，其图如下（其中(a=primary,b,c,d,e)构成一个group，a是primary）： **图1**

---

primary并不是接收到event后立即同步到backup，而是在事务的prepare阶段集中处理。前面也提到过，event肯定是属于某个view，event是按timestamps的顺序发送，这样所有的event就会形成一个viewstamps的顺序。比如我们每个view的编号 即viewid都是全序的，即每次都会单调递增，每个event的顺序也是全序，这样每次primary接收到一个数据，都可转变为一个带全序的 event，可记录为<v1.1>,<v1.2>,<v2.1>,<v2.2>...因为一个事务可以提交多个数据最后一起提交，而服务端的view会随着cohort的crash而动态调整，因此客户端在与primary通信时都 需要指定哪个事务与primary的哪个view通信，而primary回复client生成的每个event的viewstamps，如下图3：

客户端和primary都记录这些数据，以准备后续的事务提交。当客户端准备提交时，在primary接收到prepare命令时，会把其上的viewstamp记录同步到backups上，因为viewstamp全序，就保证了这些事件会以相同的顺序在backups上执行，从而得到一个一致 的状态。为了保证这一点，单靠event状态一致是不够的，还必须要求backup不能跳号执行event，比如primary要求执 行<v2.3>，但backup发现<v2.2>尚未执行，则必须等<v2.2>执行完毕后才能执 行<v2.3>。

为什么会有<v2.2>尚未执行就有<v2.3>要求的情况呢？有两个原因：一是网络波动，信息传输有时差，但这在局域网中很少发生；二是backup可能会crash后苏醒，这个情况比较常见。

Primary在向backups复制数据时并不要求所有的backups都成功，而只是要求包含自己在内的一个多数派成功即可（在viewstamps算法中，称这样的多数派为sub-majority）。这点非常重要，详细说明如下：

假如在现在时刻viewstamps系统正常运行，其所有cohort成员是confirutaion的一个多数派，记为C；

系统在多次viewchange后仍能保持一个多数派，记为X

因为C、X都为多数派，因此C、X至少存在一个公共cohort，记为O，则cohort O知道系统在C中正常运行时的所有viewstamps，新的view可以根据O还原出viewchange前的所有工作状态，从而能为是否提交事务作出 决策。如果不能保证存在多数派，则无法保证viewstamps算法的正确性，也就是说在2N+1个节点中，最多允许N个节点失败。

5. 节点失败

cohort失败的情况比较多，但假定数据可以丢失、复制、乱序，但不能出现拜占庭问题，即不能篡改消息；另假设所有的失败都是fail-stop，即失败停止，不会在失败状态继续服务。虽然假设感觉比较多，但这些假设一般的通信环境都能满足。

节点会有下面几种失败状态：

- 失败导致service无法访问
- 失败后又苏醒，丢失之前的状态
- 网络失败导致分区，比如导致cohort被分成两组，组之内的cohort可以相互访问，组之间的不能，典型的发生场景是交换机发生问题。

前两种错误会导致view change；后一种失败因为采用强制多数派的机制，保证了虽然有一个少数派的网络存在，但因为无法形成多数派而无法工作，就杜绝了存在两个viewstamps group同时工作带来的风险。

一般我们会在cohort之间保持心跳检测，一旦某个cohort在指定的时间没有收到其他cohort的心跳则认为crash，从而发起view change。从理论上来说，通过心跳来检测对方server是否crash是不可靠的，主要是单凭心跳时间，无法区分crash和busy，这个值的设 定跟应用所处的网络环境有很大关系。当然也可引入其他更复杂的crash检测机制，就不在这里作深入讨论。

6. View change

如上所述，当某个cohort通过心跳发现对方已经crash时，就发起view change，可能会有多个cohort同时发起view change，所以必须保证只能建立一个新的view，基本方法如下：（假如A、B、C同时发现D失败）

1. A构造一个新的viewid，这个view id要比A所见到的所有的view id都大，并且不同的cohort生的view id一定不能相同，这点与paxos的proposalid非常像
2. A发送一个invitation到其他活着的cohort，比如X
3. X发现A发送的view id，比自己所见到的所有view id都大，于是接收邀请并回复给A；否则，X拒绝A，不做任何回应。
4. A在接收到多数派的回应后，认为新的view已经形成，初始化新的primary；否则，无法形成新的view，一段时间后改变view id重复上述过程

在4中只是说，接收到多数派的回应，就认为新的view已经形成，要达到这个目标必须满足两个充分条件：

- 存在一个多数派cohort接收了inviitation
- 并且这个多数派中至少存在一个cohort知道之前所有的viewstamp

第一个条件比较容易验证，因为在Viewstamps算法中假定viewstamps的记录没有持久化，所以第二个条件不总是成立，比如：

- 有A(primary)、B、C三个节点，A提交事务
- event同步到B但还未到C，A crash
- A又迅速从crash状态recovery
- B与A、C发生了网络分区

此时的现状是：A、C可以连通，但都没有viewstamps记录，所以无法形成新view；B有viewstamps记录，但无法与A、C互通，所以也无法形成新View。因此能否形成新view需要下面三个加强条件：

- a majority of cohorts accepted normally, or
- crash-viewid < normal-viewid, or
- crash-viewid = normal-viewid and the primary of view normal-viewid has done a normal acceptance of the invitation.

在形成新view后，还要继续：

5.A寻找新的primary，并把各cohort回应的viewstamp发送给primary初始化其状态，如果老的primary没有crash，可以继续指定为primary；否则随机指定cohort作为primary
6. 新Primary把在初始化时，把所有正确的viewstamp发送到所有的cohort，使所有的cohort状态一致。

整个过程大概如此。

7. 并发执行

在6中的过程可能有多个cohort同时执行，比如A、B同时进行view change，所以该问题本质上还是一个选举的问题，只是对于paxos来说，是多个proposer同时proposal选择最终决议，而现在是选择新的view。

在paxos算法中使用了2个phase解决选举的唯一性问题，而上述viewstamps的过程本质上就是paxos的phase 1，但仅凭phase1是无法达成最终决议，viewstamps 算法可能并没有意识到这一点，只是认为编号高的view会被最终选择，并提出了一些避免view change并发执行的方案。由此也可看出，paxos 算法理论上比viewstamps 更完善，也有更清晰的2phase的划分。

还有一个关键问题是view在算法过程中起了什么作用，如果没有view change而仅使用一个view是否可以？在原论文中作者提到了用view的原因：

Over time thecommunication capability within a group may change as cohorts or communicationlinks fail and recover. To reflect this changing situation, each cohort runs ina view.

就是说，因为节点、网络都会失败、恢复，为了反映这一情况每个节点需要运行在一个view中。

从实际应用情况来看，view反映的是节点某个时刻的运行快照，在每次新primary被选出时，需要使用正常的节点初始化其状态，但不需要所有正常节点的数据，只需要其最后一个view的viewstamps即可，如果仅采用一个view，就会每次把所有的数据都发送的新primary。

还有一种情况是网络失败，比如A、B、C三个节点，在发生网络分区，C与A、B隔离，经过一段时间网络分区修复，A、B、C又重新联通，但C上的数 据已经与A、B不一致，当再进行primary选举时就无法判断C上的数据是否可用。如果引入一个view，当C网络分区时，A、B会有新的 viewid，而分区修复时，根据viewid能明确区分出C上的数据不是最新数据。所以，引入view就是为节点引入了一个判断数据是否是最新的标志。

这也就证明了，在primary-backup模式中，当发生primary切换的时候，如果没有一定的分布式算法，仅靠backup上的数据是无 法保证新的primary能正确同步之前的状态，也就是说任何想仅通过backup去保证primary数据正确性的做法都是徒劳。

8. 优化

并不是每次cohort失败都需要导致view change，如果primary没有失败，而仅backup失败，且失败后的cohort仍能构成多数派，则无需view change。但primary失败则需要view change。viewchange的过程与primary是无关的，primary的指定也是随机的，那为什么primary失败缺要导致view change？其实primary切换需要2步工作：

- 准备primary切换后的数据，为cohort形成一个新的view
- 选择一个cohort作为primary

重要的是第一步工作，只要第一步完成了，选择哪个cohort作为primary都不是问题。所以，表面上primary与viewchange无关，其实view change的过程就是特为primary而准备。这样是viewstamps成为选举算法的原因。

9. 结论

Viewstams 并没有从理论上完整解决选举问题，但却为leader选举及选举后的leader状态同步提出了完整的方案。

相比而言，paxos理论上更完善，2 phase的表述也更清晰，但很显然的是viewstamps不完全等同与paxos，而只是做了paxos的phase 1。

Google chubby的人曾说，所有的分布式算法都是paxos的一个特例，信矣！

《End-to-end argument in system design》读书笔记

这篇文章对网络分层体系结构的产生和发展产生过重要的影响，文中所涉猎到诸多的课题，如网络性能和代价的平衡选择，数据传输中的确认和重传机制的实现等，仍然在目前的网络设计中有着指导性的意义。“端到端”的网络设计观点，由此成为对网络结构设计的一篇经典论文，帮助我们更好的理解当前 TCP/IP、ISO 七层协议等网络分层设计原理。

一、作者的中心观点

作者提出了分布式系统下端到端的系统设计原则，即底层网络设计应注重与核心传输功能的实现，而不是花费更大的代价去实现其他的功能。作者指出，错误恢复、安全加密、重复消息限制、系统崩溃恢复、传输确认等技术实现，都支持端到端观点的成立。在网络的底层应该简化结构，把更多的功能实现，如数据确认和重传、安全加密等功能放到高层网络实现，效率会更高。

二、观点辨析

作者以文件传输过程来分析端到端网络设计的合理性：文件传输过程如图所示，

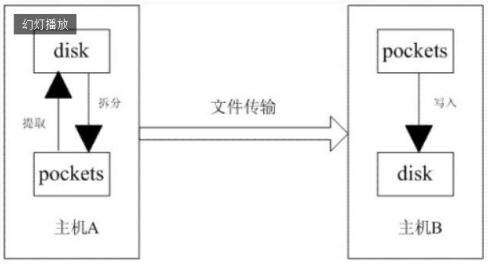

在传输过程中可能遇到诸多难以控制的风险，包括文件本身出错、通信传输过程出错、接收过程出错、数据包完整性的度量以及其他一些未知的错误发生。作者讨论了当前技术条件下解决文件传输错误的几种途径：1、进行多次的文件复制，通过多次的简单传输保证数据写入的正确性；2、端到端的数据确认和请求重传 3、进行错误检测。建立一个可靠的文件传输机制离不开底层链路的支持。

从性能分析的角度讲，基于一个不可靠的网路建立一个可靠的文件传输，底层网络可以实现完善的功能，但是权衡性能和代价，在底层实现这些功能的代价太大，不如在高层网络进行这些功能实现。实现数据的可靠传输，需要建立错误检查功能，在应用层也能实现。作者从三方面提出例证：

1、借鉴 ARPANET 网络的方法，高层可以使用 RFNM 原理实现消息确认机制，保证数据传输的准确性；

2、在高层实现数据加密功能而不是在底层实现是必要的，因为数据加密需要密钥；传输过程中数据的安全性很脆弱；数据的最终确认仍然在高层。高层对数据加密功能的实现手段具有互补性，而底层无需实现这些功能；

3、为防范网路对重复信息的抑制，高层可以实现对数据重复请求的鉴别；

4、在先进先出的信息传输机制中，信息的序列可能被打乱，高层则可以重组信息序列；

5、传输管理中，消息的确认报文最好由高层完成，底层的设计上应尽量减少冗余信息的传输。

应用于实际问题，端到端的观点分析需要做细微的甄别。如在语音传输中，人们更侧重于对声音同步性的要求而非正确率，过多的时间延迟会导致人们的反感。因此，作者指出，端到端的观点不是一个硬性的绝对规则，而是一个帮助设计应用程序和协议的设计的指导。目前，只有金融和航空领域才有能力和需求，完成底层的数据可靠性传输，在其他领域端到端系统已经能够满足错误控制和纠错处理方面的要求了。

总而言之，端到端的观点犹如奥卡姆剃刀（Occam's Razor），即如果在底层设计的功能已经超过它所能提供的必要核心业务了，那么可以考虑在其他层进行此类功能的设计。而改变的做法就是设计一个端到端的系统，负责数据的可靠传输等。

三、文章主要贡献

文章的观点和分析思路为网络的分层设计思想奠定了理论基础。作者在文章最后也指出，对于“时下”流行这种基于网络分层的想法是可取的，这样可以加强模块间的分工合作。网络分层的优越性，正是体现在底层实现的复杂和代价昂贵，因此网络设计的简易化和接口化已经成为了网络设计的基本原则。